

## A Controlled Comparison of Force Representations for Diffusion Policy Learning from UMI Demonstrations with a Wrist F/T Sensor

박지용<sup>1</sup> · 김상현<sup>1</sup>

<sup>1</sup> Robot Control and Intelligence Lab, 경희대학교 기계공학부

### Introduction

#### 배경과 문제

모방학습은 사람의 시연으로 로봇 정책을 학습한다. 시연은 사람이 로봇을 원격조종하는 텔레오퍼레이션이나, 로봇 없이 손에 든 그리퍼 (UMI) 로 모은다. UMI 는 빠르고 어디서나 되지만 영상과 자세만 기록한다 — 눌러 따라가는 접촉 태스크에서 얼마나 누르는지, 얼마나 미끄러운지는 시연에 없다.

#### 연구 목표

손목에 힘 센서를 다는 것은 최근 연구들이 시작했다. 정해지지 않은 것은 힘을 정책에 어떤 형태로 넣느냐다. 같은 데이터 · 같은 모델로 힘 없음 (E1) / 센서 값 그대로 (E2) / 물리적으로 정리한 값 (E3) 을 비교한다.



표준 UMI — 영상과 자세만 기록

### Materials and Methods




Fig. 1 파이프라인 — 세 정책은 힘 표현 단계만 다르다

#### 1 장치와 데이터



Fig. 2a 제작한 수집 장치 (손목 F/T 추가)




Fig. 2b 같은 그리퍼 · 같은 툴을 문 FR3

#### 수집 장치 — 자체 제작

표준 UMI 그리퍼 손목에 6 축 힘 / 토크 (F/T) 센서를 통합했다. 아이폰이 영상과 6-DoF 자세를 30 Hz 로, F/T 센서가 접촉력을 500 Hz 로 기록한다.

#### 세 가지 힘 표현

- E1 힘 없음 — 영상 + 자세만 (표준 UMI 와 같음)
- E2 원시 렌치 — 센서 출력 6 개 (힘 3 + 토크 3) 를 그대로
- E3 물리 구조화 — 중력을 뺀 힘, 힘 크기, 접촉 여부, 표면을 따라 / 누르는 방향 성분, 변화율 등 10 개

#### Dataset — 경사면 접촉 태스크

- 153 에피소드 · 66,353 프레임 · 37 분, 단일 셋업
- 약 12° 경사면을 고정 바로 3.7 cm/s 미끄러지며 추종, 접촉 평균 5.9 s
- 법선력 13.6 N (peak 41.6 N), 접선 저항 2.3 N
- 두 번째 표면 (종이) 150 에피소드 — 같은 접촉 바 · 같은 과제, 마찰비 0.405 ~ 0.261 (~35%). 경사는 약 2° 이내로만 일치




Fig. 3 시연의 네 단계

Fig. 4 같은 같고 마찰은 다른 두 표면

#### 2 보정




Fig. 5 센서 영점이 한 세션에 10 N 흘렀다 — 접촉력 평균 (13.6 N) 과 같은 크기다. 그래서 편향을 에피소드마다 다시 추정한다.

평가 — S1 은 후반 세션을 통째로 홀드아웃한 분할 (분포 변화 있음), S2 는 세션을 섞은 분할 (거의 i.i.d.) 이다. 지표는 접촉 구간 ( $|F| > 3$  N) 의 다음 위치 예측 오차이고, 표의 모든 수치는 시드 3 개다.

#### 중력 보상과 taring

$F_{comp} = F_{raw} - bias - m \cdot (R^T g)$ . 손에 들고 기울이는 장치라 편향만 빼면 부족하다. 정지 상태 tare 는 편향과 공구 질량을 분리하지 못해 (정지 추정 0.72 kg vs 오프라인 0.089 kg) 기울면 약 6 N 틀린다 → 자세를 바꿔가며 보정한다.

### Results

지표 : 접촉 구간 ( $|F| > 3$  N) 에서 정책이 예측한 다음 위치와 시연의 차이 (mm). 낮을수록 좋다. 시드 3 개.

Covering the condition removes the penalty




Fig. 6 단일 표면 학습 (왼쪽) 과 혼합 학습 (오른쪽) 에서 E1 vs E3. 종이 값은 검증 34 개 기준이라 표 (150 개 전체) 와 다르다.

| 접촉 오차 [mm], 3 시드 | 테이프 (학습)    | 종이 (미학습)    | 혼합 학습 → 테이프 / 종이 |
|------------------|-------------|-------------|------------------|
| E1 힘 없음          | 3.37 ± 0.10 | 4.98 ± 0.24 | 3.37 / 2.87      |
| E2 원시 렌치 6ch     | 3.41 ± 0.05 | 4.62 ± 0.15 | 3.32 / 2.92      |
| E3b 구조화 5ch      | 3.01 ± 0.07 | 5.49 ± 0.54 | —                |
| E3 구조화 10ch      | 2.99 ± 0.06 | 5.34 ± 0.22 | 3.07 / 2.79      |




Fig. 7 이득은 중력 보상 + 힘 크기 (4 채널) 에서 나타나고, 그 뒤로는 늘지 않는다

- 학습 표면 : 구조화 — 11.3% (t=-10.2). 중력 보상만 (3ch) 은 이득 없고,  $|F|$  를 더한 4ch 에서 — 10.9% — 그 뒤로는 늘지 않음
- 원시 렌치 : 이득 0% — 그러나 힘을 상수로 지우면 오차 +67% (E3 는 +162%) → 쓰되 이득 없음
- 미학습 표면 : 구조화는 양 방향 모두 나빠짐 (+7.3% / +15.9%)
- 혼합 (같은 116 개) : 종이 손해 사라져 동물, 테이프 — 9.0% 유지 · 데이터 절반 (60 개) 에서도 — 9.1% → 데이터 양 탓이 아님




Fig. 8 FR3 페루프 — (왼쪽) 한 회차, 1 초 간격. 배지 = 접촉 여부 ( $|F| \geq 3$  N): E1 은 판 위에 뜬 채 2 N, E3 는 눌러 미끄러진다. (오른쪽) 40 회, 점 = 회차 · 막대 = 평균

### Conclusions

#### 힘 표현의 이득은 학습 조건 안에서만 — 오프라인에서도, 로봇에서도

센서를 단다고 정책이 저절로 좋아지지 않는다. 원시 렌치는 어디서도 기준선과 구분되지 않지만 힘을 상수로 지우면 오차가 67 % 늘어난다 — 쓰이는 것과 도움이 되는 것은 다르다. 물리적으로 구조화한 힘은 학습 표면에서 9~11 % 이득, 미학습 표면에서는 손해 (+7~8 %) 이고, 그 표면을 학습에 넣으면 손해가 사라진다. 이득에는 중력 보상과 명시적  $|F|$  둘 다 필요했다.

FR3 페루프 (Fig. 8) 에서 같은 구조가 재현됐다. 학습 표면에서 E3 의 접촉 유지 +29 %p. 이탈 — 5 회 (d = 3.2); 미학습 종이에서는 우세가 +13 %p 로 절반 이하로 줄고 이탈 차이는 사라졌다. 더 세게 눌러서가 아니다 — 법선력을 맞춘 부분집합 (54 vs 77 %) 과 회귀에서도 우세가 남았다.

만들 사람에게 — 중력 보상한 힘과 그 크기, 네 채널이면 충분하다. 로봇이 만날 표면을 시연에 넣는 것이 표현보다 중요하다. 정책은 힘을 출력하지 않으므로 순응성은 로봇 강성으로 준다 (관절 강성 절반; 기본 강성은 5 회 중 2 회 중단).

한계 — 오프라인 시드 3 · 표면 2 · 단일 과제, 두 판 경사 약 2° 차이. 로봇 시드 1, E2 없음, 46 cm 접근 생략 (판 3 mm 위 시작), 마운트 검증은 ARKit 드리프트로 판정 불가, 법선력 5~6 N 은 절반 강성의 값. 다만 회차 수준에서는 견고하다 — 어느 한 회차를 빼도 우세가 테이프 +26 %p · 종이 +11 %p 이상이고, 두 표면 모두 E3 의 최저 회차가 E1 의 최고 회차보다 높다.

시연 · 로봇 영상  
프로젝트 페이지

